LAPORAN PROYEK UJIAN TENGAH SEMESTER

KLASIFIKASI KELAS HARGA LAPTOP BERDASARKAN SPESIFIKASI TEKNIS MENGGUNAKAN ARSITEKTUR MULTI-LAYER PERCEPTRON (MLP) DENGAN HYPERPARAMETER TUNING

Dosen Pengampu: Syanti Irviantina, S.Kom., M.Kom.

Mata Kuliah: Deep Learning

Kelompok: 4

Project ID: B10

Disusun oleh:

231112463 - Purba Tua Siregar

231111899 - Havidz Andrian

231112313 - Mikkael Raynala Tampubolon

231112081 - Ipaldi Jagarojes Sembiring

231112747 - Muhammad Dhani Irvansyah



PROGRAM STUDI S-1 TEKNIK INFORMATIKA

FAKULTAS INFORMATIKA

UNIVERSITAS MIKROSKIL

MEDAN

2026/2027

DAFTAR ISI

LAPORAN TEKNIS PROYEK.....7

1. Kompleksitas Masalah.....7

1.1 Latar Belakang dan Permasalahan.....7

1.2 Alasan Masalah Dianggap Kompleks.....7

1.3 Tantangan, Rumusan Masalah, dan Tujuan.....8

1.4 Perkembangan dari Tugas Proyek 2.....8

DATASET YANG DIGUNAKAN.....9

2.1 Sumber, Sifat, dan Format Dataset.....9

2.2 Pembentukan Kategori Harga dan Perkiraan IDR.....9

2.3 Kompleksitas dan Kualitas Dataset.....10

EXPLORATORY DATA ANALYSIS (EDA).....11

3.1 Distribusi Kelas dan Kondisi Harga.....11

3.2 Histogram Fitur Numerik.....11

3.3 Korelasi Antarfitur.....12

3.4 Contoh Sampel Setiap Kelas.....13

3.5 Temuan EDA dan Dampaknya pada Preprocessing.....13

PREPROCESSING DATA.....14

4.1 Pembersihan dan Rekayasa Fitur.....14

4.2 Penanganan Missing Value dan Outlier.....14

4.3 Standardisasi, Encoding, dan Dimensi Fitur.....14

4.4 Pembagian Data dan Pencegahan Data Leakage.....15

4.5 Augmentasi, Keseimbangan Data, dan Pipeline Tensor.....16

MODEL YANG DIGUNAKAN.....17

5.1 Jenis dan Alasan Pemilihan Model.....17

5.2 Arsitektur Baseline, Regularized, dan Tuned MLP.....17

5.3 Konfigurasi Pelatihan dan Hyperparameter Tuning.....18

5.4 Alasan Model Hasil Tuning Menjadi Fokus.....19
5.5 Dua Fitur Unik dan Bukti Dampaknya.....19
HASIL EVALUASI DAN ANALISIS.....21
6.1 Metrik Evaluasi dan Dasar Pemakaiannya.....21
6.2 Hasil Tiga Model pada Data Testing.....21
6.3 Grafik Accuracy dan Loss pada Model Utama.....22
6.4 Confusion Matrix dan Analisis Per Kelas.....23
6.5 Perbandingan Ablasi dan Stabilitas Multi-Seed.....24
6.6 Pengujian Sensitivitas dan Keterbatasan Generalisasi.....26
TEKNOLOGI YANG DIGUNAKAN.....27
7.1 Bahasa Pemrograman, Library, dan Lingkungan Eksperimen.....27
7.2 Teknologi Aplikasi dan Hosting.....27
DEPLOYMENT DAN DEMONSTRASI.....28
8.1 Status Tautan Publik dan Artefak.....28
8.2 Rangkaian Deployment yang Harus Dijalankan.....28
8.3 Prototipe Rancangan Antarmuka SDK Static.....30
8.4 Rencana Isi Video Demo dan Pengujian Aplikasi.....32
LAMPIRAN TEKNIS DAN BUKTI KODE.....34
9.1 Cuplikan Preprocessing dan Pencegahan Kebocoran Data.....34
9.2 Cuplikan Arsitektur Model dan Hyperparameter Tuning.....34
9.3 Cuplikan Dua Fitur Unik.....36
9.4 Cuplikan Pembuatan Paket SDK Static.....37
9.5 Daftar Grafik dan Tabel Pendukung.....38
DAFTAR PUSTAKA.....39
TAUTAN PROYEK UTS.....40

DAFTAR GAMBAR

Gambar 1. Distribusi kelas, harga laptop, dan jenis GPU pada data analisis.....11
Gambar 2. Histogram 10 fitur numerik dan variasi nilai spesifikasi laptop.....12
Gambar 3. Matriks korelasi fitur numerik terhadap harga asli dan kelas target.....13
Gambar 4. Diagram arsitektur MLP hasil tuning: 83 fitur masukan menjadi tiga probabilitas kelas.....17
Gambar 5. Peringkat 10 percobaan KerasTuner dan hubungan learning rate dengan skor validasi.....19
Gambar 6. Perubahan coverage dan F1 pada confidence threshold serta peringkat permutation importance.....20
Gambar 7. Perbandingan akurasi validasi bobot akhir dan akurasi testing ketiga MLP.....22
Gambar 8. Kurva accuracy training dan validation MLP hasil tuning.....22
Gambar 9. Kurva loss training dan validation MLP hasil tuning.....23
Gambar 10. Confusion matrix Model 3 pada 153 data uji.....24
Gambar 11. Perbandingan F1 makro validasi pada studi ablasi A-F.....25
Gambar 12. UI Prototype Rencana 29
Gambar 13. Prototipe input kustom tema terang (INR/IDR).....31
Gambar 14. Prototipe input kustom tema gelap (INR/IDR).....31
Gambar 15. Prototipe unggah batch tema terang (CSV/XLSX/JSON).....32
Gambar 16. Prototipe unggah batch tema gelap (CSV/XLSX/JSON).....32
Gambar 17. Cuplikan kode pemisahan data dan preprocessing yang dipelajari dari training34
Gambar 18. Cuplikan fungsi arsitektur baseline dan regularisasi MLP.....35
Gambar 19. Cuplikan kode penentuan ruang pencarian dan KerasTuner RandomSearch. . .35
Gambar 20. Cuplikan kode pengujian confidence threshold pada model hasil tuning.....36
Gambar 21. Cuplikan kode permutation importance pada data validasi.....37
Gambar 22. Cuplikan kode pemeriksaan dan daftar berkas SDK Static.....38

DAFTAR TABEL

Tabel 1. Rancangan pembagian tugas Kelompok 4 (menunggu konfirmasi anggota).....6
Tabel 2. Komponen akhir dan kebutuhan pembuktian perubahan dari Tugas Proyek 2.....8
Tabel 3. Identitas dan struktur dataset yang digunakan.....9
Tabel 4. Definisi kelas harga laptop dengan dua mata uang.....9
Tabel 5. Hasil audit kualitas dan duplikasi dataset.....10
Tabel 6. Distribusi kelas harga dalam dataset analisis.....11
Tabel 7. Contoh laptop berlabel dari data uji.....13
Tabel 8. Sebaran nilai kosong sebelum imputasi pada setiap subset.....14
Tabel 9. Kelompok fitur utama untuk pemodelan.....15
Tabel 10. Pembagian data pada percobaan utama.....15
Tabel 11. Ringkasan arsitektur ketiga model.....17
Tabel 12. Konfigurasi utama MLP hasil KerasTuner.....18
Tabel 13. Dampak dua fitur unik pada eksperimen.....20
Tabel 14. Perbandingan metrik pengujian tiga model.....21
Tabel 15. Analisis keberhasilan dan kesalahan menurut kelas.....24
Tabel 16. Ablasi model pada validasi.....25
Tabel 17. Stabilitas lima seed pada data validasi.....25
Tabel 18. Teknologi dan versi berdasarkan keluaran notebook.....27
Tabel 19. Status bukti deployment yang tersedia.....28
Tabel 20. Berkas utama pada rancangan paket SDK Static.....29
Tabel 21. Contoh nyata dari data uji untuk video demo.....33
Tabel 22. Tautan yang wajib dilengkapi sebelum pengumpulan.....40

PEMBAGIAN TUGAS ANGGOTA KELOMPOK

Pembagian tugas di bawah disajikan sebagai rancangan pembagian kerja yang dapat digunakan untuk administrasi laporan. Notebook tidak mencatat identitas penanggung jawab setiap bagian, sehingga seluruh peran dan rincian pekerjaan harus dikonfirmasi kepada anggota sebelum dokumen dikumpulkan.

Tabel 1. Rancangan pembagian tugas Kelompok 4 (menunggu konfirmasi anggota)

NIM / Nama	Peran (usulan)	Rincian pekerjaan (usulan)
231112463 — Purba Tua Siregar	Koordinator dan pengolahan data	Koordinasi; audit dataset; EDA; validasi pelaporan.
231111899 — Havidz Andrian	Preprocessing dan pipeline	Pemisahan data; imputasi; scaler/encoder; pipeline tf.data.
231112313 — Mikkael Raynala Tampubolon	Pemodelan dan tuning	Implementasi MLP, pembanding, KerasTuner dan callback.
231112081 — Ipaldi Jagarojes Sembiring	Evaluasi dan fitur unik	Confusion matrix, threshold, permutation importance, ablasi.
231112747 — Muhammad Dhani Irvansyah	Integrasi dan dokumentasi	Artefak model, frontend SDK Static, repositori, video dan laporan.

Sumber: Rancangan pengisian administratif; bukan catatan kontribusi aktual yang terverifikasi.

Catatan: Konfirmasi nama peran dan bukti pekerjaan aktual setiap anggota melalui riwayat commit, file kerja, atau penjelasan kelompok. Hindari menyampaikan tabel usulan sebagai fakta apabila pembagiannya berbeda.

LAPORAN TEKNIS PROYEK

1. Kompleksitas Masalah

1.1 Latar Belakang dan Permasalahan

Harga laptop dipengaruhi oleh banyak komponen teknis yang saling berkaitan. Kapasitas RAM yang besar belum tentu menunjukkan laptop dengan kelas harga tinggi apabila jenis prosesor, kartu grafis, penyimpanan, dan karakteristik perangkat lainnya berbeda. Karena itu, hubungan spesifikasi dan kelas harga tidak cukup dijelaskan oleh satu aturan sederhana. Kami mengangkat masalah klasifikasi kelas harga laptop agar sistem dapat mempelajari kombinasi spesifikasi tersebut secara bersamaan.

Proyek menggunakan dataset katalog laptop dari Kaggle dengan label harga dalam rupee India (INR). Kami mengelompokkan harga menjadi tiga kelas, yaitu Entry-Level, Mid-Range, dan High-End. Kelas tersebut merupakan kategori buatan berdasarkan batas numerik yang ditentukan dalam notebook, bukan pengelompokan resmi produsen maupun ukuran langsung terhadap kualitas laptop.

Fokus metode sesuai judul adalah pembangunan *Multi-Layer Perceptron* (MLP) sebagai jaringan saraf berlapis penuh, kemudian pencarian konfigurasi menggunakan KerasTuner RandomSearch. Dua MLP lain digunakan sebagai pembanding untuk menilai apakah model hasil tuning mengalami peningkatan terhadap arsitektur awal dan rancangan regularisasi manual.

1.2 Alasan Masalah Dianggap Kompleks

Data spesifikasi memuat campuran nilai numerik, kategorikal, dan teks semi-terstruktur dari katalog. Variasi penamaan prosesor, jenis RAM, kartu grafis, ukuran layar, serta masa garansi perlu dinormalisasi terlebih dahulu sebelum dapat dipelajari model. Beberapa spesifikasi mempunyai rentang angka yang jauh berbeda, sehingga jaringan yang menerima data mentah langsung berpotensi lebih sensitif terhadap fitur berskala besar.

Kesulitan tambahan muncul dari dua karakteristik data: nilai kosong pada jumlah inti dan jumlah thread prosesor, serta spesifikasi laptop yang berulang dengan nama produk yang sama atau mirip. Audit notebook menemukan 78 baris duplikat persis, 137 pengulangan nama model, dan 172 pengulangan kombinasi spesifikasi teknis. Karena itu, hasil pengujian melalui pemisahan acak harus dibaca dengan mempertimbangkan kemiripan produk antarbagian data.

1.3 Tantangan, Rumusan Masalah, dan Tujuan

Tantangan penelitian ini meliputi pengolahan fitur campuran tanpa menggunakan harga sebagai input, pemilihan konfigurasi jaringan yang tidak terlalu sederhana maupun terlalu rumit, pengendalian overfitting, serta evaluasi yang membedakan peran data latih, validasi, dan pengujian. Pertanyaan penelitian yang ditangani adalah bagaimana membangun pipeline data laptop, bagaimana kinerja MLP hasil tuning dibandingkan pembandingnya, dan bagaimana menilai batas kepercayaan serta pengaruh fitur pada prediksi.

Tujuan yang ditetapkan adalah menghasilkan pipeline preprocessing yang dapat dipakai ulang, melatih tiga arsitektur MLP dengan Model 3 sebagai fokus tuning, mengevaluasi klasifikasi menggunakan metrik per kelas dan F1 makro, menguji dua fitur unik, serta mempersiapkan satu paket inferensi untuk aplikasi Hugging Face Spaces SDK Static.

1.4 Perkembangan dari Tugas Proyek 2

Notebook akhir memperlihatkan adanya audit duplikasi, imputasi berdasarkan kelompok seri prosesor, pemisahan train/validation/test, pembandingan tiga MLP, RandomSearch, dua fitur tambahan, pengujian ablasi, dan ekspor untuk aplikasi statis. Namun, artefak Tugas Proyek 2 yang menjadi pembanding tidak dilampirkan. Oleh sebab itu, kami tidak menyatakan bahwa seluruh komponen tersebut merupakan penambahan baru dari Tugas Proyek 2 tanpa bukti versi sebelumnya.

Tabel 2. Komponen akhir dan kebutuhan pembuktian perubahan dari Tugas Proyek 2

Komponen pada notebook akhir	Bukti saat ini	Status perbandingan TP2
Audit EDA dan duplikasi	Tersedia pada Section 2	Perbedaan dengan TP2 belum diverifikasi
Imputasi dan preprocessing dari training	Tersedia pada Section 3	Perbedaan dengan TP2 belum diverifikasi
MLP baseline, regularisasi, dan tuning	Tersedia pada Section 5-7	Perbedaan dengan TP2 belum diverifikasi
Dua fitur unik, ablasi, multi-seed	Tersedia pada Section 11-12	Perbedaan dengan TP2 belum diverifikasi
Ekspor SDK Static	Kode tersedia pada Section 13	Implementasi akhir belum diuji

Sumber: Analisis isi UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, Section 2-13; artefak TP2 tidak disertakan.

DATASET YANG DIGUNAKAN

2.1 Sumber, Sifat, dan Format Dataset

Dataset diperoleh dari halaman Kaggle *Laptop Specifications and Prices Dataset* yang diterbitkan pada repositori anshsahu111. Notebook memuat mekanisme unduhan melalui kagglehub dan membaca dua berkas CSV, yaitu laptops_uncleaned.csv dan laptops_cleaned_v1.csv. Data menggambarkan katalog laptop dengan spesifikasi dan harga, sehingga diperlakukan sebagai data observasional berbasis katalog, bukan data sintetis. Riwayat pengambilan sampel dan kelengkapan pasar tidak dapat dibuktikan hanya dari berkas yang tersedia.

Berkas mentah terdiri atas 1.020 baris dan 12 kolom. Berkas hasil ekstraksi awal terdiri atas 1.018 baris dan 22 kolom. Audit menunjukkan dua baris yang tidak masuk ke berkas bersih berasal dari entri Lenovo ThinkBook Plus Gen 6 Rollable dengan pemetaan kolom yang tidak teratur. Notebook tidak merekonstruksi dua baris tersebut secara spekulatif; seluruh eksperimen mengikuti 1.018 baris dalam berkas cleaned_v1.

Tabel 3. Identitas dan struktur dataset yang digunakan

Aspek	Keterangan
Sumber	Kaggle, anshsahu111/laptop-specifications-and-prices-dataset
Format	CSV (mentah dan ekstraksi awal)
Ukuran mentah	1.020 baris × 12 kolom
Ukuran analisis	1.018 baris × 22 kolom
Masukan model	19 atribut asli → 83 fitur tertransformasi
Keluaran	3 kelas harga; softmax
Sifat data	Katalog laptop; data observasional
Mata uang target	INR; IDR sekadar ekuivalen ilustratif

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, Section 1-3.

2.2 Pembentukan Kategori Harga dan Perkiraan IDR

Harga asli dalam dataset menggunakan rupee India (INR). Kami menerapkan batas kelas yang tetap agar label konsisten: di bawah ₹50.000 sebagai Entry-Level, ₹50.000 sampai dengan ₹85.000 sebagai Mid-Range, dan di atas ₹85.000 sebagai High-End. Sebagai bantuan membaca nominal, laporan menambahkan perkiraan rupiah dengan kurs acuan ilustratif 1 INR ≈ Rp192,549 pada 9 November 2026. Kurs tersebut bukan kurs transaksi, tidak memengaruhi kelas, dan tidak membuktikan kesamaan harga jual di Indonesia.

Tabel 4. Definisi kelas harga laptop dengan dua mata uang

Kelas	Rentang INR asli	Ekuivalen IDR ilustratif
Entry-Level	< ₹50.000	< Rp9.627.450
Mid-Range	₹50.000-₹85.000	Rp9.627.450-Rp16.366.665
High-End	> ₹85.000	> Rp16.366.665

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, Section 2; kurs ilustratif dibekukan pada 9 November 2026.

2.3 Kompleksitas dan Kualitas Dataset

Kompleksitas dataset tidak berasal dari jumlah observasi yang sangat besar, melainkan dari variasi bentuk data dan hubungan antarspecifikasi. Fitur numerik antara lain rating, jumlah core, jumlah thread, kapasitas RAM, kapasitas penyimpanan, ukuran layar, resolusi, PPI, dan masa garansi. Fitur kategorikal mencakup merek, seri prosesor, tipe RAM, jenis penyimpanan, merek dan tipe GPU, sistem operasi, serta informasi layar sentuh. Kolom harga tidak diberikan kepada model sebagai fitur prediktor.

Tabel 5. Hasil audit kualitas dan duplikasi dataset

Jenis pemeriksaan	Temuan tersimpan
Nilai core_num kosong	22 nilai
Nilai threads_num kosong	77 nilai
Duplikasi baris persis (tanpa ID)	78 baris
Nama model yang berulang	137 pengulangan
Spesifikasi + harga identik	82 pengulangan
Spesifikasi teknis identik	172 pengulangan
Model sama di train dan test	24 nama model

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, Section 2-3.

Baris dengan spesifikasi ekstrem, seperti RAM sebesar 64 GB atau lebih, diperiksa dan tidak dihapus otomatis. Nilai yang jarang tidak selalu merupakan kesalahan; keputusan membuang data tanpa pemeriksaan dapat menghilangkan karakteristik laptop kelas premium. Karena terdapat contoh produk berulang, satu metrik dari pemisahan acak tidak cukup untuk membuktikan kinerja pada seluruh produk laptop yang belum pernah dilihat model.

EXPLORATORY DATA ANALYSIS (EDA)

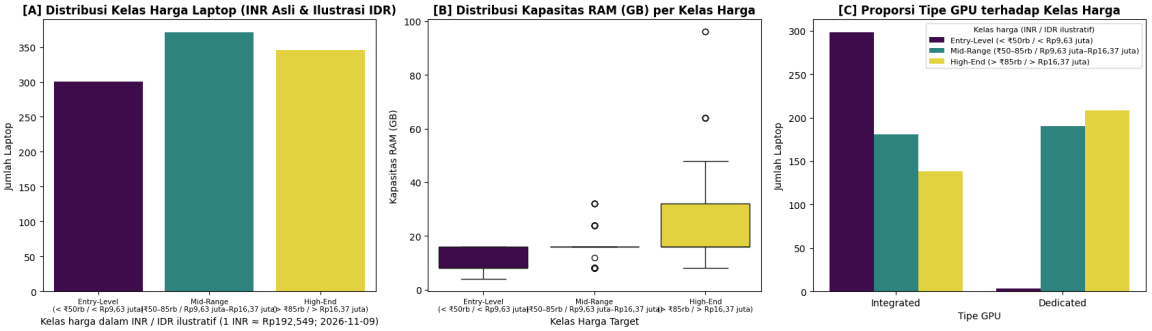
3.1 Distribusi Kelas dan Kondisi Harga

Distribusi label relatif seimbang: kelas Entry-Level berjumlah 301 sampel (29,57%), Mid-Range 371 sampel (36,44%), dan High-End 346 sampel (33,99%). Selisih antarkelas tetap diperhatikan saat menafsirkan akurasi, sehingga laporan tidak hanya bergantung pada jumlah prediksi benar secara keseluruhan.

Tabel 6. Distribusi kelas harga dalam dataset analisis

Kategori	Jumlah	Persentase
Entry-Level	301	29,57%
Mid-Range	371	36,44%
High-End	346	33,99%
Total	1.018	100,00%

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, Section 2.

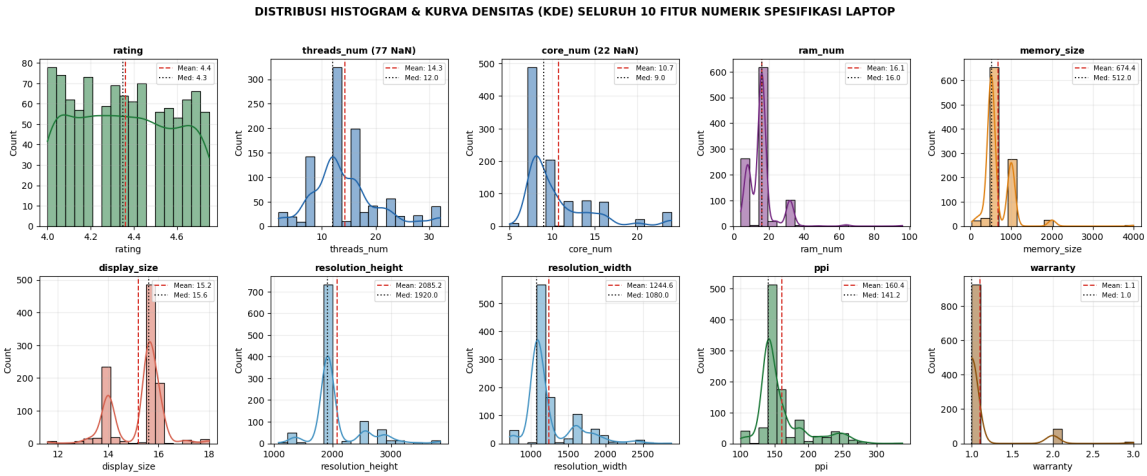


Gambar 1. Distribusi kelas, harga laptop, dan jenis GPU pada data analisis

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, output grafik Section 2.

3.2 Histogram Fitur Numerik

Histogram menunjukkan distribusi fitur numerik yang tidak seragam. Nilai kapasitas dan komponen layar mempunyai rentang yang jauh lebih lebar dibandingkan fitur seperti rating. Kondisi ini mendukung penerapan standardisasi berdasarkan statistik training, bukan membiarkan perbedaan satuan membentuk bobot awal yang tidak seimbang.

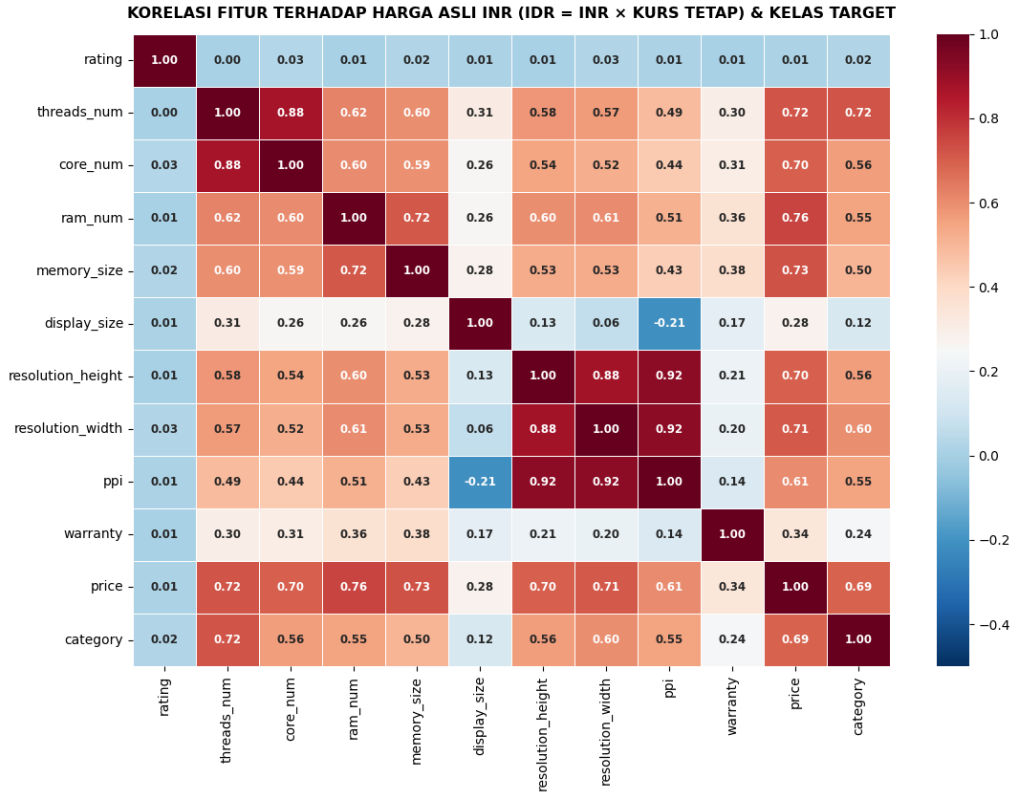


Gambar 2. Histogram 10 fitur numerik dan variasi nilai spesifikasi laptop

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, output grafik Section 2.

3.3 Korelasi Antarfitur

Matriks korelasi menggambarkan hubungan linear antarfitur numerik dan representasi kelas harga, tanpa berarti hubungan tersebut bersifat sebab-akibat. Fitur resolusi dan PPI saling terkait secara matematis karena PPI berasal dari ukuran serta resolusi layar. Kami tetap mempertahankan fitur itu dalam ruang pencarian awal dan memeriksa pengaruhnya melalui permutation importance agar interpretasi tidak semata-mata berdasarkan korelasi linear.



Gambar 3. Matriks korelasi fitur numerik terhadap harga asli dan kelas target
Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, output grafik Section 2.

3.4 Contoh Sampel Setiap Kelas

Contoh observasi berikut diambil dari tabel evaluasi Section 8, yang menautkan harga sebenarnya dengan kelas yang digunakan sebagai label. Nama model hanya dipakai sebagai identitas observasi dan tidak menjadi input untuk MLP.

Tabel 7. Contoh laptop berlabel dari data uji

Kelas aktual	Contoh sampel	Harga asli / ekuivalen
Entry-Level	Lenovo IdeaPad 3 82XQ008TIN	₹42.990 (≈ Rp8.277.682)
Mid-Range	HP Victus 15-fa1274TX	₹84.990 (≈ Rp16.364.740)
High-End	HP Omen 16-xf0081AX	₹135.999 (≈ Rp26.186.471)

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, Section 8, tabel contoh prediksi benar dan salah.

3.5 Temuan EDA dan Dampaknya pada Preprocessing

Hasil EDA menjadi alasan untuk melakukan empat tindakan utama: memastikan penyetaraan data kategorikal sebelum encoding, mengisi nilai kosong dengan median yang dipelajari dari training, melakukan standardisasi numerik, dan memperlakukan duplikasi sebagai keterbatasan generalisasi. Proporsi tiga kelas yang tidak terlalu jauh berbeda tidak mendorong penggunaan oversampling otomatis, karena perubahan distribusi data tanpa kebutuhan jelas dapat menghasilkan evaluasi yang lebih sulit ditafsirkan.

Analisis jumlah kata atau word count tidak diterapkan karena objek penelitian bukan data teks; teks spesifikasi hanya diolah untuk mengekstraksi fitur yang dapat dipelajari. Sampel per kelas disajikan melalui identitas laptop, harga, dan label, bukan ilustrasi citra.

PREPROCESSING DATA

4.1 Pembersihan dan Rekayasa Fitur

Pengolahan dimulai dengan pemeriksaan struktur CSV, penyeragaman data kategori, dan pengubahan spesifikasi yang semula berupa teks menjadi angka atau kategori. Informasi RAM diuraikan menjadi kapasitas serta jenis memori, sedangkan kerapatan piksel layar atau PPI dihitung dari resolusi dan ukuran layar. Proses rekayasa fitur bersifat deterministik dan tidak menggunakan label harga untuk menghitung statistik imputasi.

Dua catatan katalog yang tidak masuk ke versi cleaned_v1 tidak dimasukkan kembali secara manual karena pemetaan atribut pada baris sumbernya tidak konsisten. Audit tetap mencatatnya agar perubahan jumlah baris dari 1.020 menjadi 1.018 dapat ditelusuri.

4.2 Penanganan Missing Value dan Outlier

Ditemukan 77 nilai kosong pada threads_num dan 22 pada core_num. Kami membagi data lebih dahulu, lalu menerapkan GroupMedianImputer yang mempelajari median menurut seri prosesor (iter) hanya dari data training. Apabila jumlah data tidak mencukupi pada suatu kelompok atau kelompoknya belum dikenal, digunakan median keseluruhan yang juga dihitung dari training. Metode tersebut mengurangi risiko informasi validasi dan testing masuk ke tahap pembelajaran preprocessing.

Tabel 8. Sebaran nilai kosong sebelum imputasi pada setiap subset

Subset	threads_num	core_num	Total
Training (712)	54	18	72
Validation (153)	12	3	15
Testing (153)	11	1	12
Keseluruhan	77	22	99

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, Section 3.

Penanganan outlier dilakukan secara konservatif. Notebook mengaudit nilai spesifikasi ekstrem, tetapi tidak memangkas semua observasi berdasarkan aturan IQR karena perangkat premium memang dapat mempunyai RAM atau penyimpanan yang jauh lebih besar. Angka harga juga tidak dipakai dalam standardisasi atau imputasi fitur prediktor.

4.3 Standardisasi, Encoding, dan Dimensi Fitur

Setelah imputasi, fitur numerik diproses oleh StandardScaler untuk menempatkan nilainya pada skala yang dapat dibandingkan. Fitur kategorikal diproses dengan OneHotEncoder(handle_unknown="ignore") sehingga kategori baru tidak menyebabkan

kegagalan transformasi. Pipeline dipelajari dari data training; data validasi dan testing hanya menjalankan transform dengan parameter yang sudah dibekukan.

Tabel 9. Kelompok fitur utama untuk pemodelan

Jenis	Contoh atribut	Prosedur
Numerik (10)	rating, core_num, threads_num, ram_num, memory_size, display_size, resolution_height, resolution_width, warranty, ppi	Median kelompok (jika diperlukan) dan StandardScaler
Kategorikal (9)	brand_name, processor_brand, iter, ram_type, memory_type, gpu_brand, gpu_type, os, Touch_Screen	OneHotEncoder dengan kategori dari training
Target (1)	price_class (0, 1, 2)	Softmax 3 kelas; tidak menjadi fitur masukan
Kolom audit	price, price_idr, model	Tidak digunakan sebagai input jaringan

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, Section 2-4.

Hasil gabungan preprocessing mempunyai 83 kolom numerik bertipe float32. Jumlah tersebut berasal dari 10 fitur numerik dan representasi one-hot dari sembilan fitur kategorikal. Dimensi transformasi perlu diperiksa setiap kali preprocessor dan model dimuat kembali agar data baru masuk ke layer input dengan urutan kolom yang sama.

4.4 Pembagian Data dan Pencegahan Data Leakage

Pemisahan dilakukan secara stratified dengan proporsi 70% training, 15% validation, dan 15% testing. Training digunakan untuk mempelajari parameter MLP serta seluruh statistik preprocessing; validasi digunakan untuk tuning, callback, dan pemilihan confidence threshold; testing digunakan untuk mengevaluasi konfigurasi yang sudah ditetapkan. Proporsi ini menjaga representasi kelas dalam tiap subset.

Tabel 10. Pembagian data pada percobaan utama

Subset	Jumlah	Entry-Level	Mid-Range	High-End
Training	712	211	259	242
Validation	153	45	56	52
Testing	153	45	56	52

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, Section 3.

Audit nama produk menunjukkan 24 nama model muncul di training dan testing. Ini tidak membuktikan label target langsung bocor melalui input, tetapi meningkatkan risiko

estimasi terlalu optimistis terhadap laptop yang mirip. Sebagai analisis sensitivitas, notebook juga melakukan pembagian group-disjoint berdasarkan nama model, yang akan dibahas terpisah pada evaluasi.

4.5 Augmentasi, Keseimbangan Data, dan Pipeline Tensor

Augmentasi citra atau teks tidak digunakan karena dataset berupa data tabular spesifikasi. Kami tidak menerapkan SMOTE maupun oversampling pada percobaan inti karena distribusi kelas masih relatif berimbang dan perlu menjaga arti kategori harga. Setelah preprocessing, data dibangun menjadi train_ds, val_ds, dan test_ds menggunakan tf.data.Dataset.from_tensor_slices; hanya training yang diacak. Seluruh subset menggunakan batch berukuran 32 dan prefetch untuk menyiapkan data secara efisien.

Pemeriksaan pada notebook mengonfirmasi bentuk tensor training (712, 83), validasi (153, 83), dan testing (153, 83), dengan tipe fitur float32 dan label int64. Label mempunyai rentang 0, 1, dan 2, tanpa NaN dan infinity setelah transformasi.

MODEL YANG DIGUNAKAN

5.1 Jenis dan Alasan Pemilihan Model

Model utama adalah Deep Neural Network (DNN) dengan arsitektur Multi-Layer Perceptron. Lapisan Dense memungkinkan jaringan menggabungkan pengaruh fitur numerik dan kategorikal yang sudah diubah menjadi vektor. Arsitektur CNN tidak dipilih karena dataset tidak memiliki hubungan ketetanggaan dua dimensi seperti piksel pada citra. Proyek tidak menggunakan arsitektur CNN ataupun transfer learning.

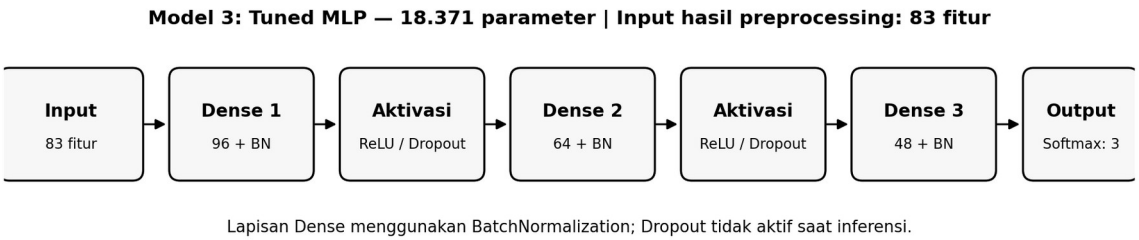
5.2 Arsitektur Baseline, Regularized, dan Tuned MLP

Tabel 11. Ringkasan arsitektur ketiga model

Model	Hidden layer	Penguatan pelatihan	Parameter
Model 1 — Baseline	64 → 32	SGD; tanpa BN/Dropout/L2	7.555
Model 2 — Regularized	128 → 64 → 32	Adam; BN; Dropout; L2	22.083
Model 3 — Tuned	96 → 64 → 48	KerasTuner; Adam; BN; Dropout; L2	18.371

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, Section 5-7.

Pada model hasil tuning, vektor masukan berisi 83 fitur. Lapisan Dense pertama menggunakan 96 neuron, dilanjutkan Batch Normalization, ReLU, dan Dropout 0,2. Lapisan kedua menggunakan 64 neuron dengan pemrosesan serupa, sedangkan lapisan ketiga berisi 48 neuron sebelum softmax pada tiga kelas. Jumlah parameter hasil model.summary() adalah 18.371, yang terdiri atas 17.955 parameter trainable dan 416 parameter nontrainable Batch Normalization.



Gambar 4. Diagram arsitektur MLP hasil tuning: 83 fitur masukan menjadi tiga probabilitas kelas

Sumber: Disusun ulang dari model.summary() notebook Section 7; ukuran layer dan jumlah parameter mengikuti output aktual.

5.3 Konfigurasi Pelatihan dan Hyperparameter Tuning

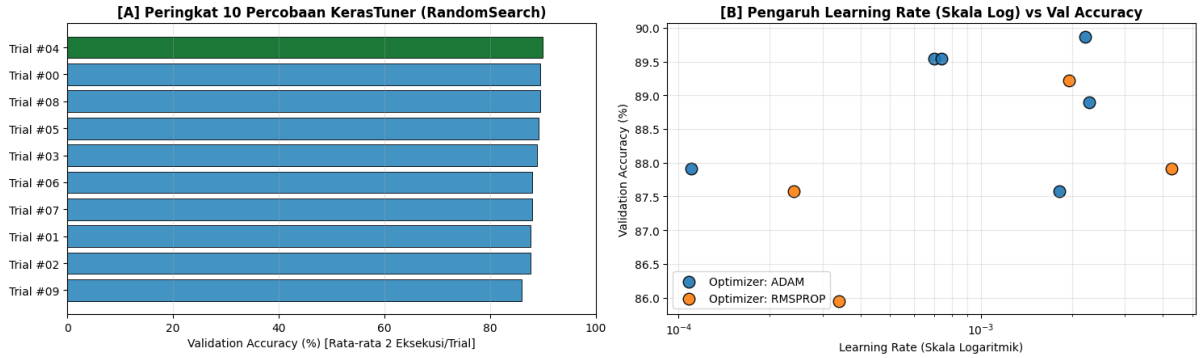
Model 1 menjadi baseline menggunakan SGD dengan learning rate 0,01 dan maksimal 50 epoch. Model 2 menggunakan Adam dengan learning rate 0,001, Batch Normalization, Dropout 0,3/0,2, L2, dan callback EarlyStopping. Model 3 diperoleh melalui KerasTuner RandomSearch dengan 10 trial serta dua eksekusi pada setiap trial. Ruang pencarian mencakup jumlah hidden layer, jumlah neuron, optimizer, learning rate, Dropout, dan nilai L2, dengan sampel skala logaritmik untuk parameter kontinu tertentu.

Tabel 12. Konfigurasi utama MLP hasil KerasTuner

Hyperparameter	**Hasil pada notebook**
Trial terbaik	Trial #04
Jumlah hidden layer	3
Neuron tiap hidden layer	96, 64, 48
Optimizer	Adam
Learning rate awal	0,0022119679
Dropout	0,2 pada dua layer awal
Regularisasi L2	0,0000195287
Jumlah parameter	18.371
Epoch retraining	36; bobot terbaik dari epoch 21
Loss	SparseCategoricalCrossentropy
Batch	32
Monitoring	ReduceLROnPlateau, EarlyStopping, ModelCheckpoint, CSVLogger

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, Section 6-7, output pelatihan dan hasil best_hp.

Setelah pencarian selesai, model dibangun ulang dari hyperparameter yang terpilih, lalu dilatih menggunakan ReduceLROnPlateau dan EarlyStopping. Retraining berhenti pada epoch ke-36 dan mengembalikan bobot dari epoch ke-21 karena validation loss mencapai minimum pada titik tersebut. Akurasi validasi puncak 90,20% pada epoch lain bukan metrik dari bobot yang akhirnya digunakan. Perbedaan tersebut dinyatakan secara terpisah pada hasil evaluasi.



Gambar 5. Peringkat 10 percobaan KerasTuner dan hubungan learning rate dengan skor validasi

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, output grafik Section 6.

5.4 Alasan Model Hasil Tuning Menjadi Fokus

Fokus proyek ditetapkan oleh judul, yaitu MLP dengan hyperparameter tuning. Karena itu, Model 3 menjadi model utama untuk evaluasi, interpretasi fitur, dan rancangan deployment. Model 1 dan Model 2 tetap dilaporkan sebagai pembanding yang membantu menjelaskan dampak perubahan arsitektur serta keterbatasan tuning dengan ruang pencarian dan sumber daya yang tersedia. Model utama tidak diganti hanya berdasarkan akurasi testing yang lebih tinggi pada pembanding.

5.5 Dua Fitur Unik dan Bukti Dampaknya

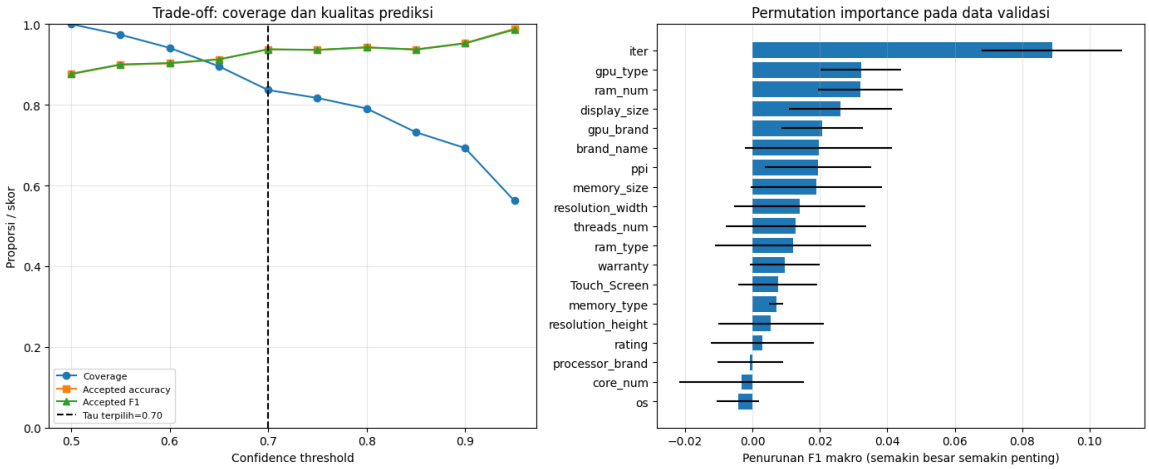
Fitur unik pertama ialah confidence threshold untuk menandai prediksi dengan skor probabilitas tertinggi di bawah ambang terpilih. Ambang 0,70 dipilih pada data validasi, dengan kriteria keseimbangan antara cakupan prediksi yang diterima dan F1 makro. Mekanisme ini tidak mengubah probabilitas model, melainkan menambah status “Perlu Ditinjau” ketika kepastian keluaran relatif rendah.

Fitur kedua ialah permutation importance pada data validasi. Nilai satu fitur asli diacak berulang sebanyak 10 kali, lalu penurunan F1 makro dibandingkan dengan skor dasar. Pengacakan dilakukan di tingkat kolom fitur asli, bukan pada satu indikator one-hot secara terpisah, sehingga satu kategori tetap diperlakukan sebagai satu atribut. Metode tersebut membantu mengidentifikasi fitur yang paling diandalkan jaringan, tetapi tidak membuktikan pengaruh kausal.

Tabel 13. Dampak dua fitur unik pada eksperimen

Fitur	Indikator utama	Hasil nyata
Confidence threshold	Ambang terpilih dari validation	0,70
Confidence threshold	Coverage data test	126/153 (82,35%)
Confidence threshold	Akurasi pada prediksi diterima	89,68%
Confidence threshold	Kesalahan yang ditandai untuk ditinjau	14 dari 27 kesalahan
Permutation importance	Penurunan F1 terbesar: iter	0,08892
Permutation importance	Penurunan F1: gpu_type	0,03215
Permutation importance	Penurunan F1: ram_num	0,03196

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, Section 11.



Gambar 6. Perubahan coverage dan F1 pada confidence threshold serta peringkat permutation importance

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, output grafik Section 11.

HASIL EVALUASI DAN ANALISIS

6.1 Metrik Evaluasi dan Dasar Pemakaiannya

Kami memakai accuracy untuk melihat jumlah prediksi benar secara keseluruhan; precision untuk menilai ketepatan prediksi suatu kelas; recall untuk mengukur seberapa banyak anggota kelas aktual dikenali; dan F1 makro untuk merangkum kemampuan tiga kelas dengan bobot yang sama. Confusion matrix dipakai untuk melihat arah kesalahan, sedangkan loss dan learning curve membantu menilai perkembangan training serta jarak terhadap validation.

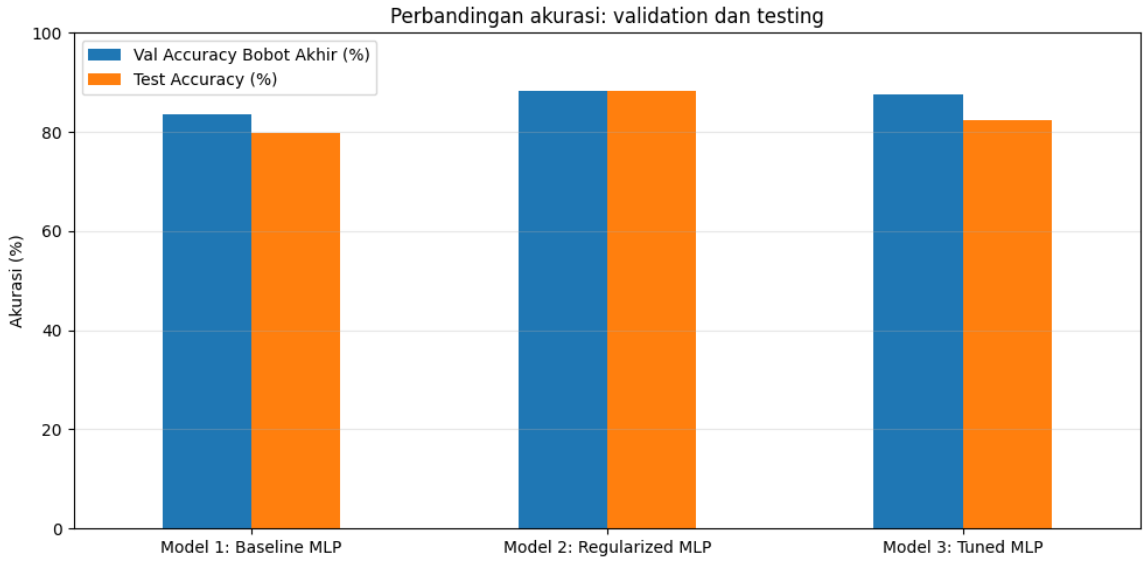
6.2 Hasil Tiga Model pada Data Testing

Tabel 14. Perbandingan metrik pengujian tiga model

Model	Accuracy	Precision makro	Recall makro	F1 makro
Model 1 — Baseline	79,74%	0,7974	0,8065	0,7990
Model 2 — Regularized	88,24%	0,8824	0,8887	0,8843
Model 3 — Tuned (utama)	82,35%	0,8244	0,8323	0,8256

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, Section 8 dan Section 10.

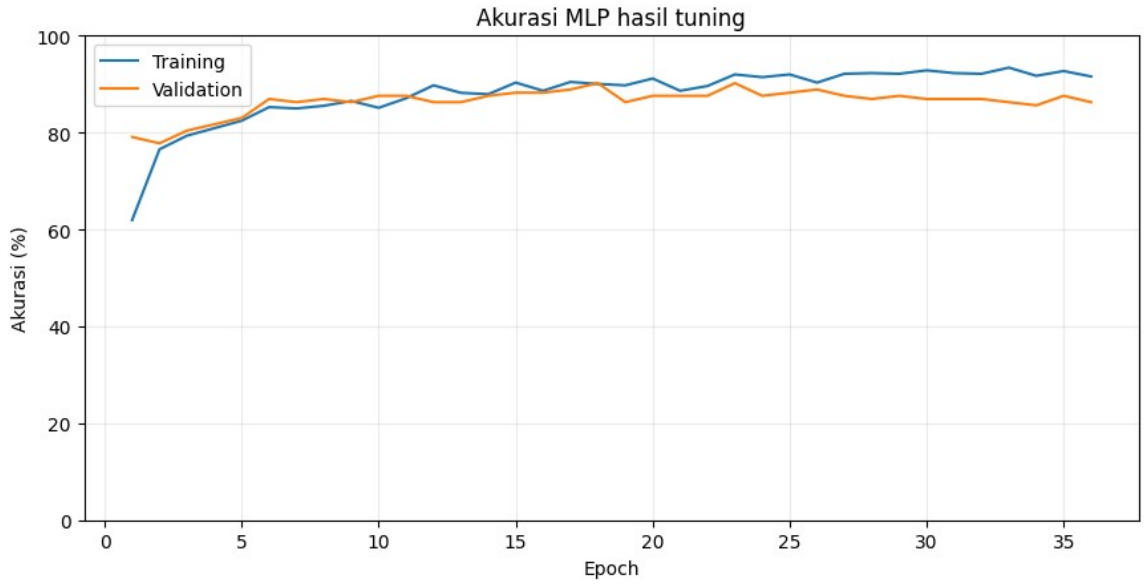
Model 3 mencapai 126 prediksi benar dari 153 data uji, sehingga 27 contoh masih salah klasifikasi. Dibandingkan Model 1, akurasi meningkat 2,61 poin persentase dan F1 makro meningkat sekitar 0,0266. Akan tetapi, Model 2 memperoleh akurasi dan F1 lebih tinggi daripada Model 3. Dengan demikian, manfaat tuning tidak boleh dinyatakan sebagai kemenangan terhadap seluruh model pembanding; hasil menunjukkan peningkatan terhadap baseline dan adanya keterbatasan pencarian parameter yang digunakan.



Gambar 7. Perbandingan akurasi validasi bobot akhir dan akurasi testing ketiga MLP
Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, output grafik Section 10.

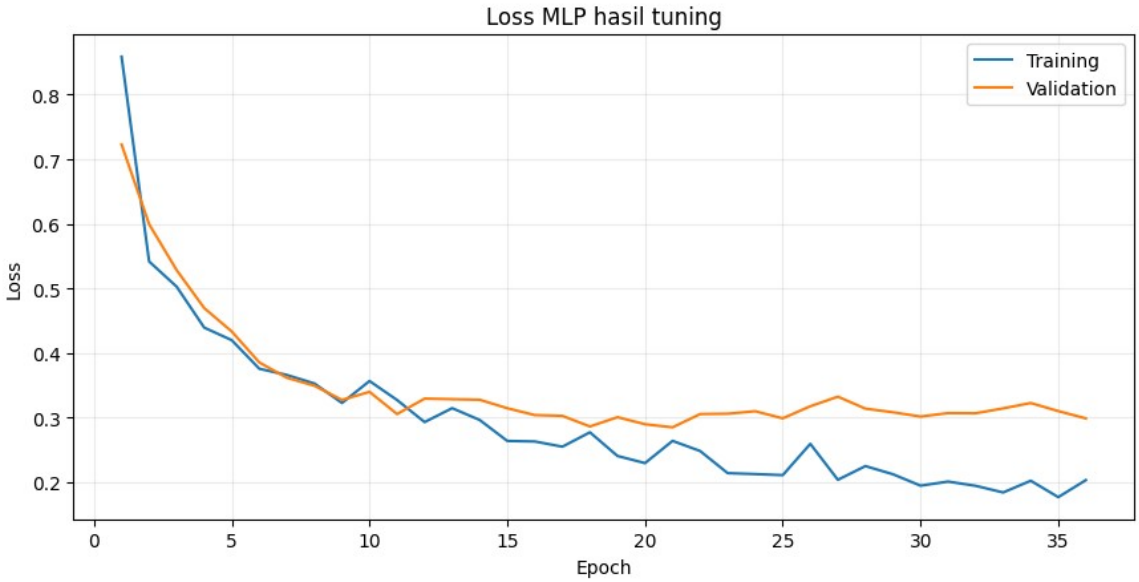
6.3 Grafik Accuracy dan Loss pada Model Utama

Kurva training dan validation memperlihatkan bahwa pembelajaran model pada awal pelatihan berlangsung cukup cepat, kemudian perbaikannya melambat. Model terbaik menurut validation loss dipulihkan dari epoch 21. Saat pelatihan berlanjut hingga epoch 36, selisih kurva training dan validation perlu dipandang sebagai indikasi kemampuan generalisasi yang terbatas, bukan bukti model selalu akan menghasilkan prediksi yang benar pada data baru.



Gambar 8. Kurva accuracy training dan validation MLP hasil tuning

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, output grafik Section 14, diekstrak dari riwayat Section 7.

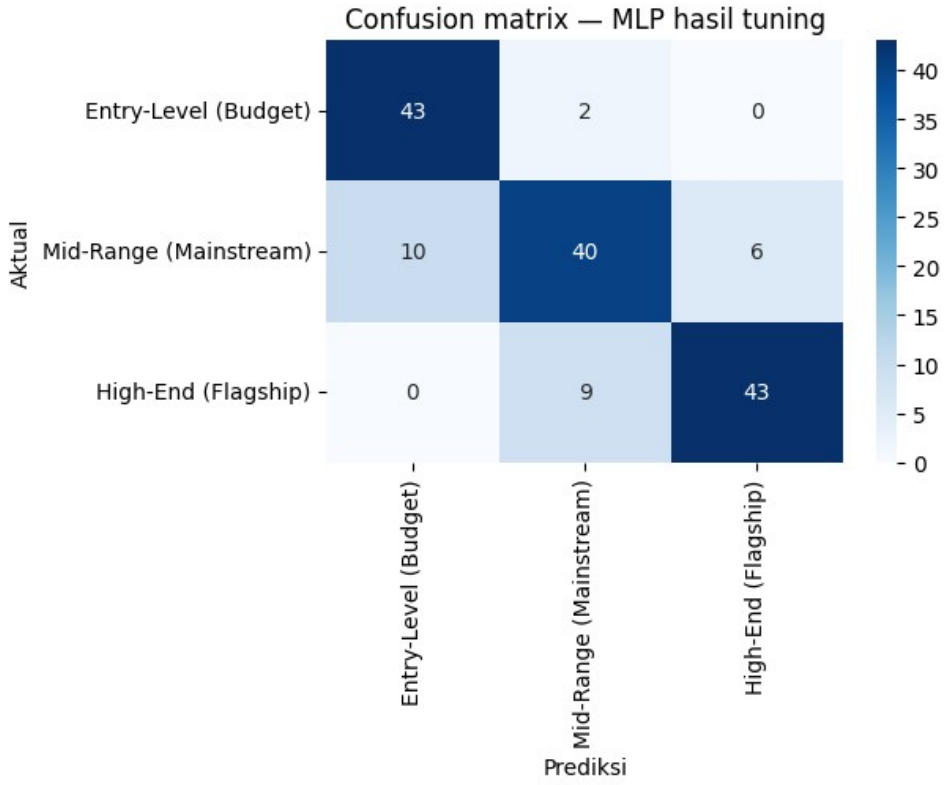


Gambar 9. Kurva loss training dan validation MLP hasil tuning

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, output grafik Section 14, diekstrak dari riwayat Section 7.

6.4 Confusion Matrix dan Analisis Per Kelas

Confusion matrix memperlihatkan kelas Entry-Level memperoleh 43 prediksi benar dari 45 sampel, dengan dua sampel bergeser ke Mid-Range. Dari 56 sampel Mid-Range, hanya 40 yang tepat, 10 diprediksi Entry-Level, dan enam diprediksi High-End. Pada kelas High-End, 43 dari 52 sampel benar dan sembilan diprediksi Mid-Range. Karena itu, Mid-Range memiliki recall terendah, yaitu sekitar 71,43%.



Gambar 10. Confusion matrix Model 3 pada 153 data uji

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, output grafik Section 14 (evaluasi model dari Section 8).

Tabel 15. Analisis keberhasilan dan kesalahan menurut kelas

Kelas aktual	Benar	Salah	Recall
Entry-Level (45)	43	2	95,56%
Mid-Range (56)	40	16	71,43%
High-End (52)	43	9	82,69%

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, Section 8/14, confusion matrix model utama.

Kelas Mid-Range lebih sering keliru karena spesifikasinya dapat bertumpang tindih dengan laptop pada kelas lebih murah maupun lebih mahal. Penjelasan ini merupakan interpretasi yang masuk akal berdasarkan pola kesalahan, bukan pembuktian penyebab untuk setiap perangkat. Pemeriksaan lebih rinci memerlukan penelusuran contoh salah klasifikasi dan fitur yang memengaruhinya.

6.5 Perbandingan Ablasi dan Stabilitas Multi-Seed

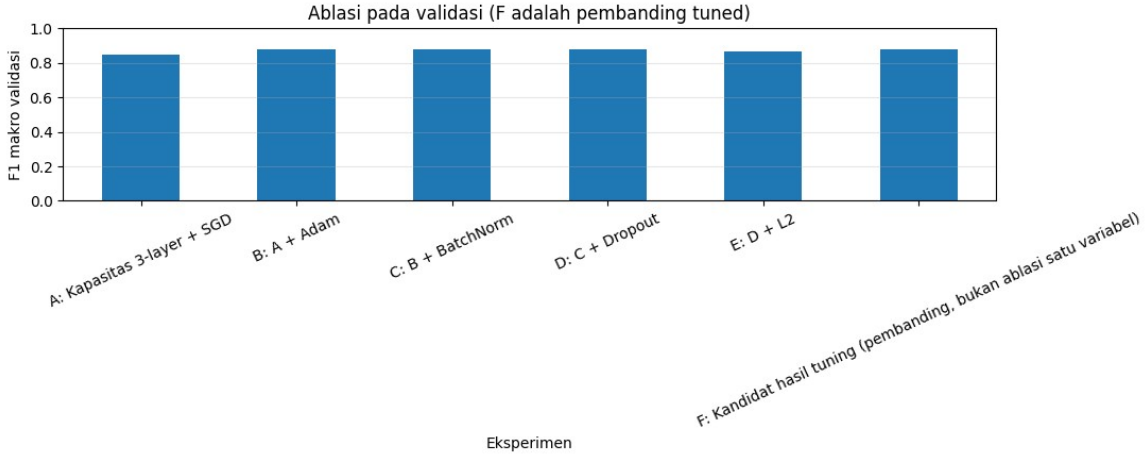
Eksperimen ablasi menggunakan arsitektur yang dikendalikan secara bertahap. Percobaan A memakai SGD, B mengganti optimizer menjadi Adam, C menambah Batch Normalization, D menambah Dropout, dan E menambah regularisasi L2. Kandidat F

adalah model hasil tuning sebagai pembanding, bukan satu langkah tambahan langsung pada rangkaian ablasi.

Tabel 16. Ablasi model pada validasi

Skenario	Accuracy validasi	F1 makro validasi	Loss validasi
A. Kapasitas 3 layer + SGD	84,97%	0,8502	0,3794
B. A + Adam	87,58%	0,8763	0,3273
C. B + BatchNorm	87,58%	0,8758	0,3035
D. C + Dropout	87,58%	0,8771	0,2814
E. D + L2	86,93%	0,8694	0,3023
F. Hasil tuning (pembanding)	87,58%	0,8769	0,2849

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, Section 12.



Gambar 11. Perbandingan F1 makro validasi pada studi ablasi A-F

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, output grafik Section 12.

Penambahan Adam dari skenario A ke B meningkatkan F1 makro validasi dari 0,8502 menjadi 0,8763. Penambahan Batch Normalization dan Dropout mengubah loss, tetapi tidak secara konsisten menaikkan accuracy. L2 pada skenario E justru menurunkan skor relatif terhadap D pada eksekusi ini. Hasil tersebut menegaskan bahwa pengaruh regularisasi bergantung pada konfigurasi dan kondisi eksperimen, bukan sekadar jumlah teknik yang ditambahkan.

Tabel 17. Stabilitas lima seed pada data validasi

Model	Rerata accuracy	SD accuracy (pp)	Rerata F1 ± SD
Model 1 — Baseline	84,97%	2,01	0,84979 ± 0,02031
Model 2 — Regularized	87,45%	0,55	0,87490 ± 0,00528

Model	Rerata accuracy	SD accuracy (pp)	Rerata F1 ± SD
Model 3 — Tuned	87,71%	0,85	0,87765 ± 0,00865

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, Section 12, seed 42/52/62/72/82.

Model 3 memiliki rerata F1 validasi tertinggi pada lima seed yang digunakan, tetapi selisih reratanya kecil. Simpangan baku dalam tabel bersifat deskriptif untuk lima ulangan pelatihan pada pembagian data yang sama; angka tersebut tidak dapat diperlakukan sebagai interval kepercayaan hasil populasi laptop secara umum.

6.6 Pengujian Sensitivitas dan Keterbatasan Generalisasi

Pada pemisahan tambahan yang memastikan nama model laptop tidak bertumpang tindih antarsubset, evaluasi memakai 713 data training, 160 validasi, dan 145 testing, dengan overlap nama model nol. Akurasi validasi yang tercatat adalah 88,75% dan akurasi pengujian sebesar 82,07%, dengan F1 makro testing sekitar 0,8246. Eksperimen ini merupakan uji sensitivitas, bukan benchmark independen, karena ruang tuning sebelumnya telah dirancang dengan pemisahan acak.

Hasil uji tambahan tersebut menunjukkan bahwa perubahan cara membagi data dapat mengubah ukuran sampel dan gambaran generalisasi. Selain itu, sebagian produk memiliki spesifikasi identik dengan harga berbeda, sehingga jaringan tidak selalu dapat memisahkan kelas hanya dari informasi teknis yang tersedia. Dataset mencerminkan katalog dari satu sumber dan tidak mewakili seluruh variasi harga pasar Indonesia.

TEKNOLOGI YANG DIGUNAKAN

7.1 Bahasa Pemrograman, Library, dan Lingkungan Eksperimen

Seluruh eksperimen dijalankan dalam notebook Python melalui Google Colab. Berdasarkan keluaran Section 1, runtime menggunakan Python 3.13.18 pada sistem Linux x86_64 dengan akselerator CPU standar. Informasi ini mengikuti lingkungan yang benar-benar tercetak pada sesi notebook, bukan spesifikasi GPU yang diasumsikan tersedia.

Tabel 18. Teknologi dan versi berdasarkan keluaran notebook

Komponen	Versi / peran
Python	3.13.18
TensorFlow / Keras	2.21.0; definisi, training, evaluasi MLP
KerasTuner	1.4.8; RandomSearch hyperparameter
scikit-learn	1.6.1; splitting, preprocessing, metrik
pandas	2.2.3; tabel dan pengolahan data
NumPy	2.4.6; operasi matriks dan tensor
joblib	1.6.0; penyimpanan preprocessor
Google Colab	Notebook; Linux x86_64; CPU Standard
Matplotlib	Visualisasi EDA dan evaluasi (versi tidak dicetak)
Kagglehub	Akuisisi dataset (versi tidak dicetak)

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, Section 1 dan penggunaan library di Section 2-14.

7.2 Teknologi Aplikasi dan Hosting

Perancangan deployment memakai Hugging Face Spaces dengan SDK Static, bukan Gradio. Halaman index.html memuat antarmuka pengguna, app.js menangani input dan tampilan hasil, sedangkan inference.js menjalankan standardisasi, encoding, dan perhitungan layer MLP di browser. Berkas model_browser.json menyimpan bobot yang diekspor dari Keras, dan preprocessing_browser.json menyimpan parameter pemrosesan hasil fit pada training.

Penyajian harga di aplikasi menggunakan ambang harga asli INR dan ekuivalen IDR ilustratif. Aplikasi memberi label kelas prediksi, probabilitas tiap kelas, status perlu ditinjau apabila confidence kurang dari 0,70, serta ringkasan permutation importance yang telah dihitung pada validasi. Screenshot pengujian aplikasi publik telah diperoleh; namun kesetaraan numerik antara keluaran browser dan TensorFlow tetap memerlukan arsip pemeriksaan tersendiri.

DEPLOYMENT DAN DEMONSTRASI

8.1 Status Tautan Publik dan Artefak

Kode pada Section 13 menyiapkan ekspor Model 3 dan aset SDK Static. Pada notebook yang dilampirkan, sel tersebut tidak mempunyai output eksekusi tersimpan. Setelah itu, tim menunjukkan Space publik Xkazuya/LAPTOP-CLASSIFIER yang berjalan melalui screenshot uji input kustom dan batch CSV/XLSX/JSON pada 9 November 2026. Bukti ini menunjukkan penggunaan aplikasi, tetapi bukan pengganti rekaman hasil uji kesamaan probabilitas JavaScript terhadap TensorFlow.

Tabel 19. Status bukti deployment yang tersedia

Tahap	Status bukti saat audit
Training dan evaluasi MLP	Tersedia output pada Section 5-12
Pembuatan model_browser.json dan aset SDK Static	Tersedia kode Section 13; belum ada output tersimpan
Uji kesamaan JavaScript dengan Keras	Kode pengujian ada; hasil eksekusi belum tersedia
Unggah ke Hugging Face Space	Space publik tersedia di https://huggingface.co/spaces/Xkazuya/LAPTOP-CLASSIFIER; screenshot uji kustom dan batch telah diberikan, riwayat unggah belum dilampirkan
Repository GitHub Kelompok 4	Repository publik tersedia: https://github.com/x-kzy/UTS-DEEP-LEARNING; paket final disiapkan untuk di-push
Video demonstrasi dan deployment	Tautan belum diberikan

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, Section 13; pemeriksaan output yang tersimpan.

8.2 Rangkaian Deployment yang Harus Dijalankan

Tahapan deployment ditetapkan sesuai kode, yaitu: (1) menyimpan Model 3 hasil tuning beserta preprocessor; (2) mengekspor median kelompok, mean dan scale numerik, urutan kategori one-hot, serta bobot tiap layer menjadi JSON; (3) menyiapkan index.html, app.js, inference.js, README.md, dan metadata; (4) menguji inferensi JavaScript dengan masukan yang sama seperti TensorFlow; (5) membuat Space dengan SDK Static, mengunggah berkas, dan menguji ulang antarmuka pada URL publik.

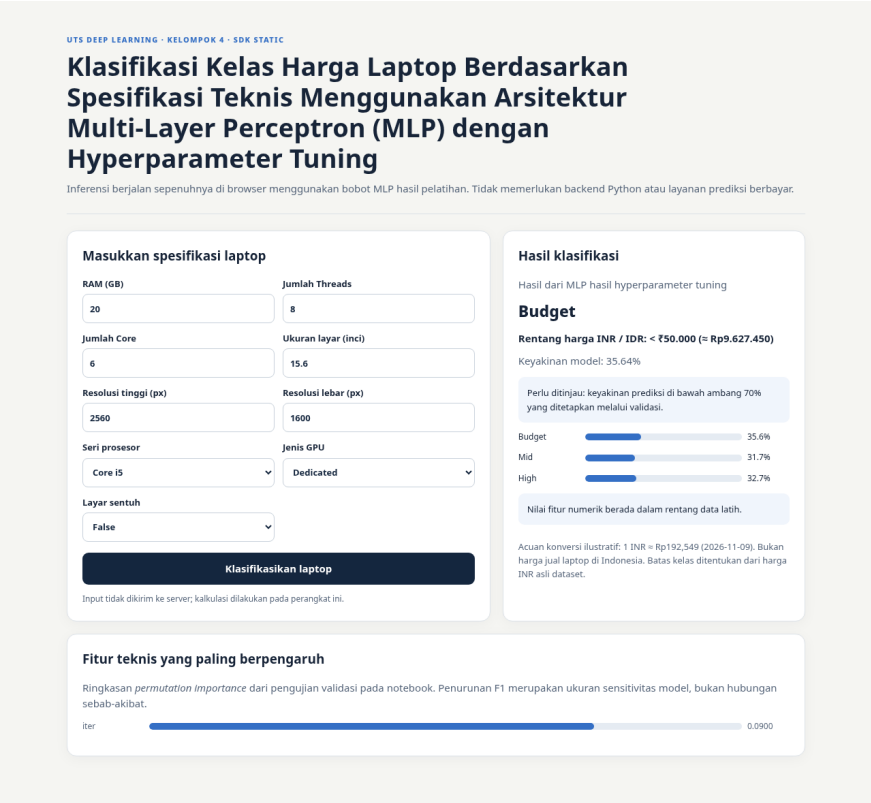
README Space harus memuat metadata YAML sdk: static dan app_file: index.html. SDK Static tidak menjalankan backend Python ketika pengguna meminta prediksi, sehingga file model_browser.json dan preprocessing_browser.json harus tersedia

bersamaan dengan JavaScript yang memuatnya. Tidak diperlukan requirements.txt pada runtime frontend statis ini.

Tabel 20. Berkas utama pada rancangan paket SDK Static

Berkas	Fungsi
README.md	Metadata Space dan petunjuk penggunaan
index.html	Halaman dan formulir input spesifikasi
app.js	Antarmuka, validasi input, hasil prediksi
inference.js	Transformasi fitur dan inferensi lapisan jaringan
model_browser.json	Bobot, bias, BN, dan konfigurasi layer
preprocessing_browser.json	Statistik imputasi, scaler dan kategori encoder
feature_schema.json	Rentang input, jenis fitur dan ambang confidence
class_labels.json	Label tiga kelas dan rentang INR/IDR
evaluation_results.json	Ringkasan bukti evaluasi dari notebook

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, Section 13, daftar static_files dan kode pembangkitan artefak.



Gambar 12. UI Prototype Rencana

Sumber: Gambar dari pengujian komponen UI lokal terdahulu; bukan tangkapan layar aplikasi yang telah dipublikasikan dan bukan bukti inferensi model asli.

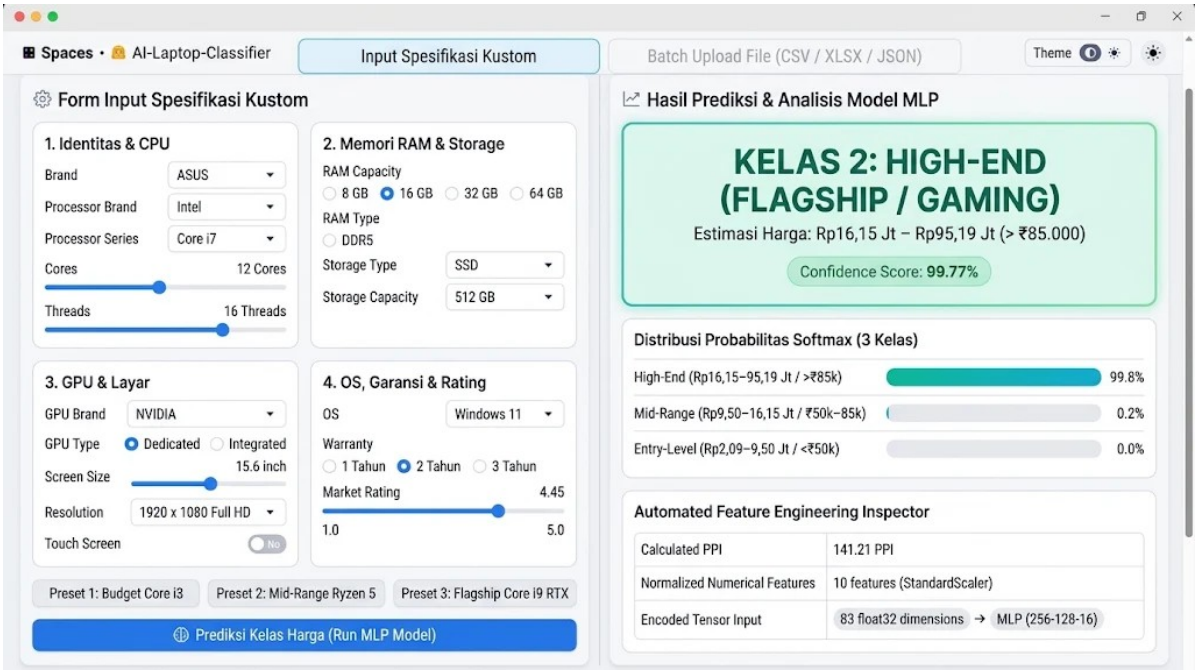
Bukti pengujian antarmuka publik telah diberikan melalui screenshot hasil prediksi input kustom dan tiga berkas batch. Dokumen repository juga menyertakan keempat screenshot dan ringkasan hasil 18, 40, dan 72 input simulasi. Sebagai pemeriksaan lanjutan, kelompok perlu mengarsipkan hasil uji kesetaraan probabilitas JavaScript terhadap Keras dan dokumentasi riwayat deployment; screenshot yang tersedia tidak otomatis membuktikan uji tersebut telah dilakukan.

8.3 Prototipe Rancangan Antarmuka SDK Static

Sebagai acuan desain antarmuka Hugging Face Spaces dengan SDK Static, kami menyiapkan empat gambar prototipe yang memperlihatkan dua mode warna dan dua alur penggunaan: klasifikasi satu laptop melalui formulir spesifikasi dan rancangan unggah katalog untuk prediksi massal. Keempat gambar ini merupakan ilustrasi rancangan (mockup), bukan tangkapan layar aplikasi publik maupun bukti pengujian model pada Hugging Face.

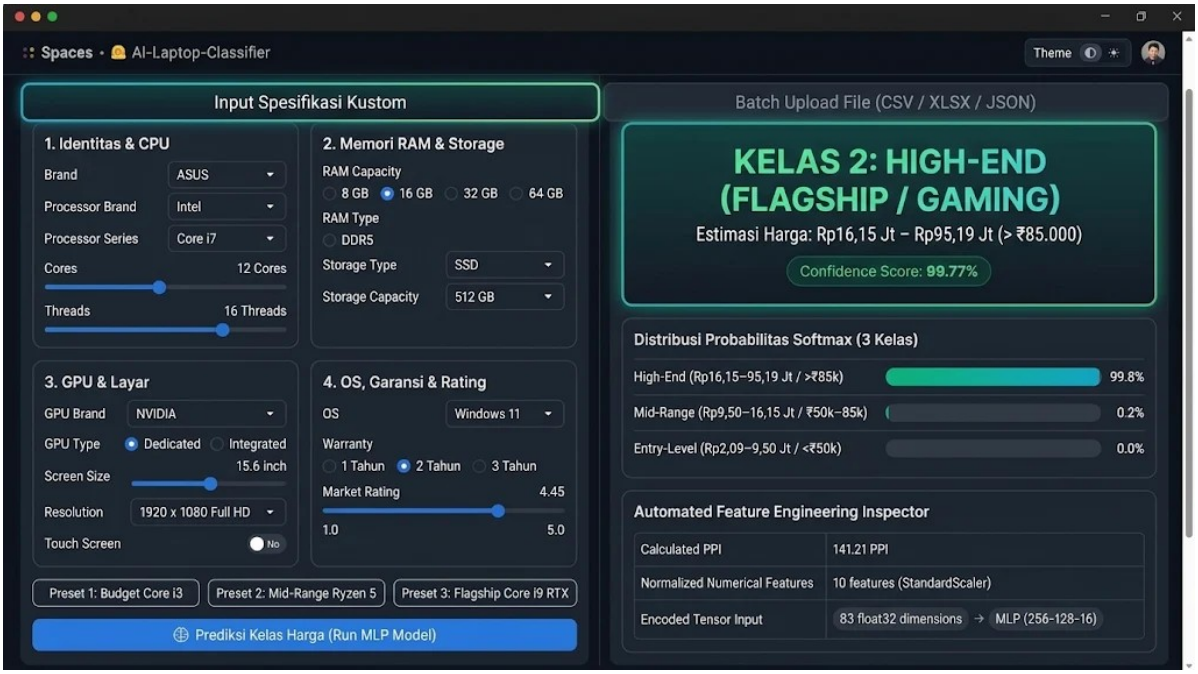
Penting: seluruh nilai confidence, probabilitas, contoh 48 laptop, nominal harga, pilihan fitur, dan arsitektur “MLP (256-128-16)” yang terlihat pada gambar hanyalah konten prototipe. Hasil notebook utama menggunakan MLP hasil tuning 96-64-48 dengan 18.371 parameter, sedangkan konversi laporan memakai acuan 1 INR ≈ Rp192,549. Karena itu, angka pada gambar tidak digunakan sebagai hasil eksperimen, tidak menggantikan metrik pengujian Section 6, dan belum menunjukkan bahwa fasilitas upload CSV/XLSX/JSON sudah berfungsi pada deployment final.

Rancangan prediksi spesifikasi tunggal



Gambar 13. Prototipe input kustom tema terang (INR/IDR)

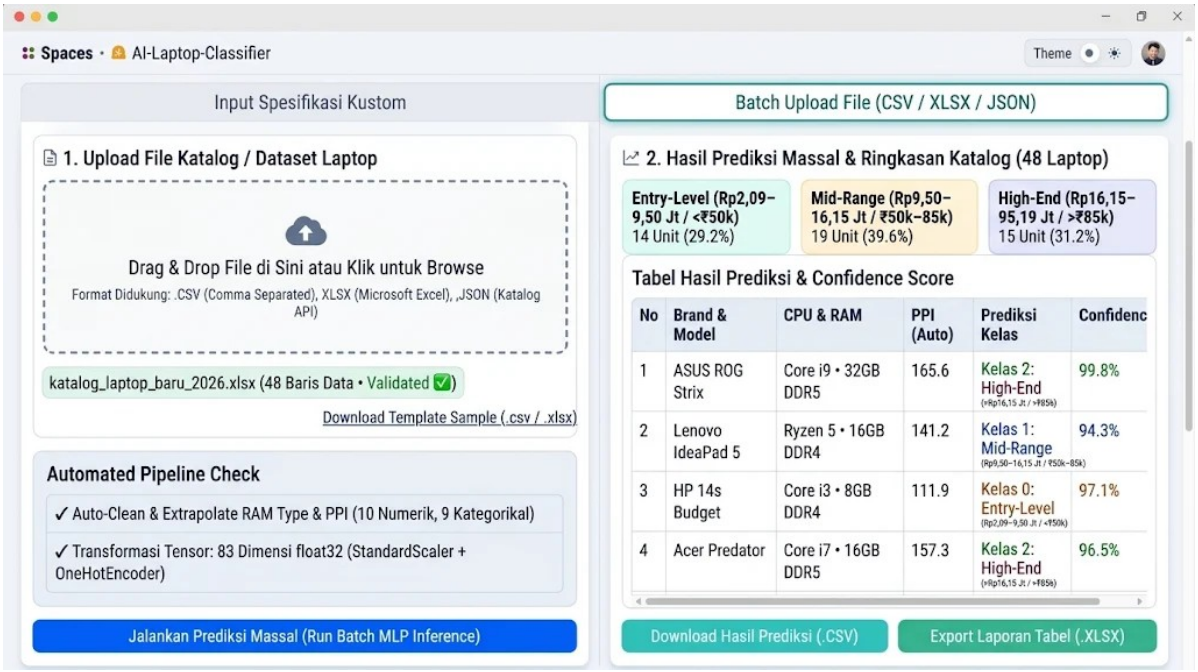
Sumber: Prototipe UI yang dilampirkan sebagai referensi desain; bukan hasil deployment atau pengujian model final.



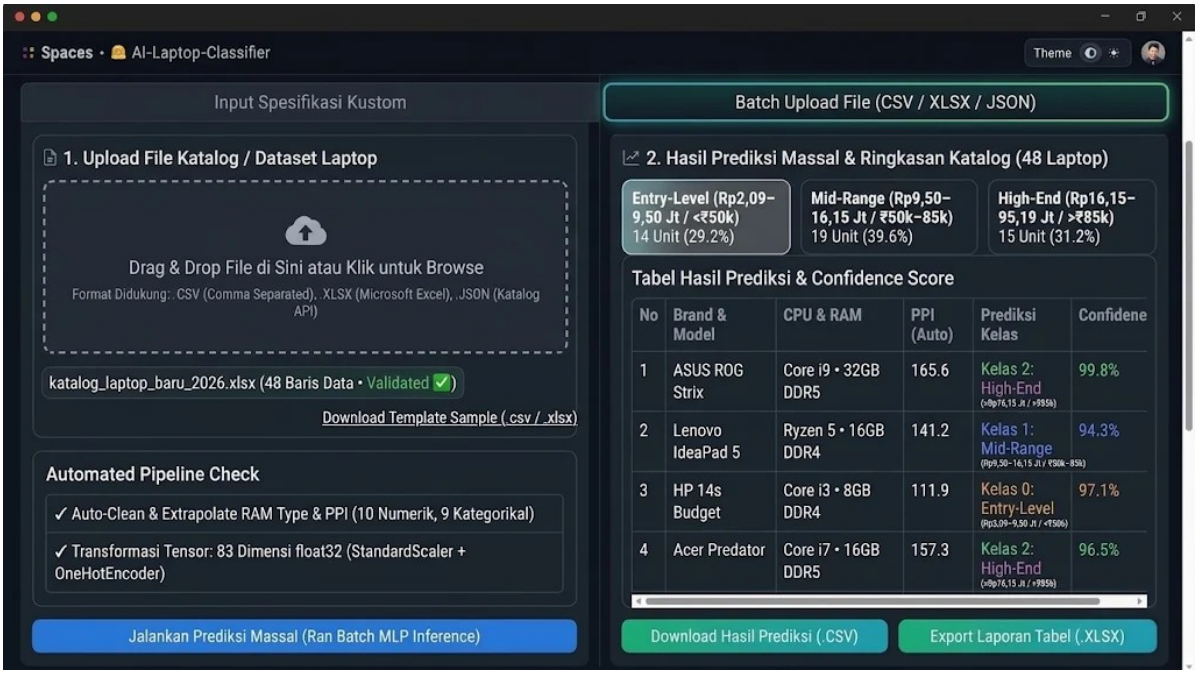
Gambar 14. Prototipe input kustom tema gelap (INR/IDR)

Sumber: Prototipe UI yang dilampirkan sebagai referensi desain; bukan hasil deployment atau pengujian model final.

Rancangan prediksi massal dari berkas katalog



Gambar 15. Prototipe unggah batch tema terang (CSV/XLSX/JSON)
Sumber: Prototipe UI yang dilampirkan sebagai referensi desain; bukan hasil deployment atau pengujian model final.



Gambar 16. Prototipe unggah batch tema gelap (CSV/XLSX/JSON)
Sumber: Prototipe UI yang dilampirkan sebagai referensi desain; bukan hasil deployment atau pengujian model final.

Rancangan dua mode warna ditujukan untuk meningkatkan keterbacaan pada penggunaan desktop. Pada prototipe tab unggah massal, alur yang ditunjukkan mencakup

pemilihan berkas, validasi kolom, pratinjau prediksi tiga kelas, serta ekspor hasil. Fitur batch, unduhan template, ekspor Excel, dan tombol preset masih berstatus rancangan; realisasinya harus disesuaikan dengan fungsi JavaScript serta data kategorikal yang didukung preprocessor final. Bukti implementasi final baru dapat dicantumkan setelah aplikasi terpublikasi dan hasil prediksinya diperiksa.

8.4 Rencana Isi Video Demo dan Pengujian Aplikasi

Video demonstrasi perlu memperlihatkan identitas proyek, dataset dan tiga kelas harga, alasan pemakaian MLP, konfigurasi hasil KerasTuner, evaluasi dan confusion matrix, penggunaan input laptop baru pada antarmuka, serta dua fitur unik. Dalam contoh yang mempunyai label asli, kelompok dapat menampilkan satu prediksi benar dan satu salah; nilai confidence perlu dibandingkan dengan status peninjauan yang diberikan sistem.

Tabel 21. Contoh nyata dari data uji untuk video demo

Contoh	Harga INR / IDR	Kelas aktual → prediksi
Lenovo IdeaPad 3 82XQ008TIN	₹42.990 / ≈ Rp8.277.682	Entry-Level → Entry-Level (benar)
HP Victus 15-fa1274TX	₹84.990 / ≈ Rp16.364.740	Mid-Range → Mid-Range (benar)
HP Omen 16-xf0081AX	₹135.999 / ≈ Rp26.186.471	High-End → High-End (benar)
Infinix Zero Book Ultra AI PC	₹85.990 / ≈ Rp16.557.289	High-End → Mid-Range (salah)

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, Section 8, contoh hasil pengujian dengan harga aktual.

Selain prediksi pada data uji yang sudah mempunyai label, kelompok dapat menggunakan input laptop baru untuk menunjukkan alur penggunaan aplikasi. Namun, input simulasi tanpa harga aktual tidak boleh diberi keterangan benar atau salah karena tidak memiliki ground truth. Bagian video deployment baru lengkap setelah URL Hugging Face aktif dan perbandingan hasil frontend dengan model asli berhasil.

LAMPIRAN TEKNIS DAN BUKTI KODE

9.1 Cuplikan Preprocessing dan Pencegahan Kebocoran Data

Cuplikan berikut berasal langsung dari kode Section 3. Inti pengendaliannya adalah pemisahan data sebelum proses fit serta pemakaian pipeline yang dibekukan bagi validasi dan pengujian. Definisi lengkap GroupMedianImputer tersimpan dalam modul preprocessors.py yang ditulis oleh notebook.

Cuplikan kode aktual • Section 3 • baris 73-91

```
# 3. MEMBANGUN PIPELINE PRAPROSES TERPADU (IMPUTER + SCALER + ONE-HOT ENCODER)
# ------------------------------------------------------------------------------
col_transformer = ColumnTransformer(
    transformers=[
        ('num', StandardScaler(), num_features),
        ('cat', OneHotEncoder(handle_unknown='ignore', sparse_output=False), cat_features)
    ]
)

preprocessor = Pipeline([
    ('group_imputer', GroupMedianImputer(group_col='iter', target_cols=('core_num', 'threads_num'), min_samples=3)),
    ('feature_encoder', col_transformer)
])

# Fit HANYA pada X_train, kemudian transform secara konsisten pada X_train, X_val, dan X_test
X_train_scaled = preprocessor.fit_transform(X_train).astype(np.float32)
X_val_scaled   = preprocessor.transform(X_val).astype(np.float32)
X_test_scaled  = preprocessor.transform(X_test).astype(np.float32)

```

Gambar 17. Cuplikan kode pemisahan data dan preprocessing yang dipelajari dari training
Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, kode Section 3, baris 73-91.

9.2 Cuplikan Arsitektur Model dan Hyperparameter Tuning

Model pembanding serta model utama memakai TensorFlow/Keras. Model utama tidak didefinisikan secara manual setelah pencarian, melainkan dibangun dari best_hp hasil

KerasTuner. Struktur layer pada cuplikan ini sesuai dengan model.summary() dan jumlah parameter yang ditampilkan pada Section 7.

Cuplikan kode aktual • Section 5 • baris 18-56

```
# 2. Arsitektur Model 2: Regularized & BatchNorm MLP (128 -> 64 -> 32)
# ------------------------------------------------------------------------------
def build_regularized_mlp(input_dim, num_classes):
    model = tf.keras.Sequential([
        tf.keras.layers.Input(shape=(input_dim,), name='input_layer'),

        tf.keras.layers.Dense(128, kernel_regularizer=tf.keras.regularizers.l2(1e-4), name='dense_1'),
        tf.keras.layers.BatchNormalization(name='bn_1'),
        tf.keras.layers.Activation('relu', name='relu_1'),
        tf.keras.layers.Dropout(0.3, name='dropout_1'),

        tf.keras.layers.Dense(64, kernel_regularizer=tf.keras.regularizers.l2(1e-4), name='dense_2'),
        tf.keras.layers.BatchNormalization(name='bn_2'),
        tf.keras.layers.Activation('relu', name='relu_2'),
        tf.keras.layers.Dropout(0.2, name='dropout_2'),

        tf.keras.layers.Dense(32, kernel_regularizer=tf.keras.regularizers.l2(1e-4), name='dense_3'),
        tf.keras.layers.BatchNormalization(name='bn_3'),
        tf.keras.layers.Activation('relu', name='relu_3'),

        tf.keras.layers.Dense(num_classes, activation='softmax', name='output_layer')
    ], name='Model_2_Regularized_MLP')
    return model

# Menampilkan ringkasan arsitektur kedua model
baseline_mlp = build_baseline_mlp(INPUT_DIM, NUM_CLASSES)
regularized_mlp = build_regularized_mlp(INPUT_DIM, NUM_CLASSES)

print("=== RINGKASAN ARSITEKTUR MODEL 1: BASELINE MLP (64 -> 32) ===")
baseline_mlp.summary()
print("\n=== RINGKASAN ARSITEKTUR MODEL 2: REGULARIZED & BATCHNORM MLP (128 -> 64 -> 32) ===")
regularized_mlp.summary()

# Pelatihan Model 1: Baseline MLP (SGD standar lr=0.01, 50 epoch)
tf.keras.utils.set_random_seed(SEED)
baseline_mlp.compile(
    optimizer=tf.keras.optimizers.SGD(learning_rate=0.01),
    loss=tf.keras.losses.SparseCategoricalCrossentropy(),
    metrics=['accuracy']
```

Gambar 18. Cuplikan fungsi arsitektur baseline dan regularisasi MLP

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, kode Section 5, baris 18-56.

Cuplikan kode aktual • Section 6 • baris 49-75

```
        loss=tf.keras.losses.SparseCategoricalCrossentropy(),
        metrics=['accuracy']
    )
    return model

# Inisialisasi KerasTuner RandomSearch (10 Percobaan pada Data Validasi, 2 Eksekusi/Trial)
tuner = kt.RandomSearch(
    hypermodel=build_tunable_mlp,
    objective='val_accuracy',
    max_trials=10,
    executions_per_trial=2,
    seed=SEED,
    directory='kt_laptop_mlp_dir',
    project_name='laptop_price_mlp_tuning',
    overwrite=True
)

search_early_stop = tf.keras.callbacks.EarlyStopping(
    monitor='val_loss', patience=8, restore_best_weights=True
)

print("Memulai pencarian Hyperparameter dengan KerasTuner RandomSearch (10 Trials, 2 Executions/Trial)...")
tuner.search(
    train_ds,
    validation_data=val_ds,
    epochs=45,
    callbacks=[search_early_stop],
```

Gambar 19. Cuplikan kode penentuan ruang pencarian dan KerasTuner RandomSearch

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, kode Section 6, baris 49-75.

9.3 Cuplikan Dua Fitur Unik

Fitur confidence memisahkan prediksi yang diterima otomatis dari prediksi yang memerlukan pemeriksaan. Permutation importance mengacak fitur asli pada data validasi secara berulang, kemudian menghitung perubahan F1 makro. Keduanya memanfaatkan model hasil tuning yang sama, sehingga tidak ada pergantian model diam-diam antara evaluasi dan fitur unik.

Cuplikan kode aktual • Section 11 • baris 37-78

```
37      raise RuntimeError('Tidak ada ambang yang lolos syarat coverage 80%; periksa data validasi.')
38  chosen_threshold_row = eligible.sort_values(
39      ['Accepted Macro F1', 'Coverage', 'Threshold'],
40      ascending=[False, False, True], kind='stable'
41  ).iloc[0]
42  OPTIMAL_TAU = float(chosen_threshold_row['Threshold'])
43  print('=== FITUR 1: HASIL KALIBRASI AMBANG PADA DATA VALIDASI ===')
44  display(thresh_val_df.round(4))
45  print(f'Ambang dipilih dari validasi: tau={OPTIMAL_TAU:.2f}, '
46        f'coverage={chosen_threshold_row["Coverage"]:.2%}, '
47        f'accepted F1={chosen_threshold_row["Accepted Macro F1"]:.4f}')
48
49  # Satu evaluasi ambang terpilih pada data test, tanpa mengubah tau berdasarkan hasil test.
50  mask_test = max_conf_test >= OPTIMAL_TAU
51  n_accept = int(mask_test.sum())
52  if n_accept == 0:
53      raise RuntimeError('Ambang terpilih tidak menerima satu pun sampel pada data test.')
54  base_f1 = f1_score(y_test, pred_cls_test, average='macro', zero_division=0)
55  mask_err = y_test != pred_cls_test
56  threshold_test_df = pd.DataFrame([{
57      'Threshold dari validasi': OPTIMAL_TAU,
58      'Total test': int(len(y_test)),
59      'Diterima otomatis': n_accept,
60      'Ditinjau': int((~mask_test).sum()),
61      'Coverage test': float(mask_test.mean()),
62      'Akurasi semua test': float(accuracy_score(y_test, pred_cls_test)),
63      'F1 makro semua test': float(base_f1),
64      'Akurasi test yang diterima': float(accuracy_score(y_test[mask_test], pred_cls_test[mask_test])),
65      'F1 makro test yang diterima': float(f1_score(
66          y_test[mask_test], pred_cls_test[mask_test], average='macro', zero_division=0
67      )),
68      'Total kesalahan awal': int(mask_err.sum()),
69      'Kesalahan yang ditandai untuk tinjauan': int(np.sum(mask_err & (~mask_test))),
70      'Kesalahan yang masih diterima otomatis': int(np.sum(mask_err & mask_test)),
71  }])
72  print('\n=== FITUR 1: PENGUJIAN AMBANG TETAP PADA DATA TEST ===')
73  display(threshold_test_df.round(4))
74
75  # Fungsi yang sama dipakai dalam uji dan dapat digunakan oleh antarmuka SDK Static.
76  def predict_with_confidence_review(df_input, model_obj, prep_obj, tau=None):
77      tau = OPTIMAL_TAU if tau is None else float(tau)
78      raw = df_input.copy()
```

Gambar 20. Cuplikan kode pengujian confidence threshold pada model hasil tuning
Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, kode Section 11, baris 37-78.

Cuplikan kode aktual • Section 11 • baris 91-116

```
# Semua nilai yang ditampilkan berasal dari hasil prediksi yang baru dihitung.
all_original_features = num_features + cat_features
K_REPEATS = 10
baseline_val_f1 = f1_score(y_val, pred_cls_val, average='macro', zero_division=0)
rng_perm = np.random.default_rng(SEED)
permutation_rows = []
for col_name in all_original_features:
    drops = []
    for repeat in range(K_REPEATS):
        X_perm = X_val.copy()
        X_perm[col_name] = rng_perm.permutation(X_perm[col_name].to_numpy())
        transformed = preprocessor.transform(X_perm).astype(np.float32)
        perm_pred = final_model.predict(transformed, verbose=0).argmax(axis=1)
        perm_f1 = f1_score(y_val, perm_pred, average='macro', zero_division=0)
        drops.append(baseline_val_f1 - perm_f1)
    permutation_rows.append({
        'Nama Fitur Asli': col_name,
        'Jenis Fitur': 'Numerik' if col_name in num_features else 'Kategorikal',
        'Penurunan F1 Rata-rata': float(np.mean(drops)),
        'Simpangan Baku': float(np.std(drops, ddof=1)),
        'Jumlah Ulangan': K_REPEATS,
    })
perm_importance_df = pd.DataFrame(permutation_rows).sort_values(
    'Penurunan F1 Rata-rata', ascending=False
).reset_index(drop=True)
perm_importance_df.insert(0, 'Peringkat', np.arange(1, len(perm_importance_df)+1))
```

Gambar 21. Cuplikan kode permutation importance pada data validasi

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, kode Section 11, baris 91-116.

9.4 Cuplikan Pembuatan Paket SDK Static

Kode pada Section 13 menyiapkan keluaran JavaScript dan JSON, serta mekanisme pengujian antarlapisan sebelum paket diunggah. Karena hasil eksekusi Section 13 tidak tersimpan pada berkas yang diberikan, lampiran ini merupakan bukti *implementasi kode yang dirancang*, bukan bukti deployment yang sudah selesai.

Cuplikan kode aktual • Section 13 • baris 320-359

```
320       browser_probs = np.asarray(json.loads(lines[-1].split('=', 1)[1]), dtype=np.float64)
321       max_diff = float(np.max(np.abs(python_predictions - browser_probs)))
322       assert browser_probs.shape == python_predictions.shape
323       assert np.allclose(browser_probs, python_predictions, atol=2e-3, rtol=1e-3), (
324           f'Prediksi browser berbeda terlalu jauh dari Keras (maks: {max_diff}).'
325       )
326       assert np.array_equal(np.argmax(browser_probs, axis=1), np.argmax(python_predictions, axis=1)), (
327           'Label prediksi di browser tidak sama dengan prediksi Keras.'
328       )
329       print(f'Uji JavaScript vs Keras pada {len(probe_rows)} data uji: LULUS; '
330             f'selisih probabilitas maksimum {max_diff:.8f}.')
331   else:
332       print('Node.js tidak tersedia: kode JS lolos ekspor, tetapi perbandingan probabilitas '
333             'browser vs Keras perlu dijalankan di lingkungan dengan Node.js atau browser.')
334
335   # 7. Paket khusus Hugging Face Static: hanya berkas yang dibutuhkan browser.
336   static_files = [
337       'README.md', 'index.html', 'app.js', 'inference.js',
338       'model_browser.json', 'preprocessing_browser.json',
339       'feature_schema.json', 'class_labels.json',
340       'evaluation_results.json', 'tuning_hyperparameters.json',
341   ]
342   for filename in static_files:
343       assert (ARTIFACT_DIR / filename).is_file(), 'Artefak Static belum tersedia: '+filename
344   zip_path = Path('HuggingFace_Spaces_Kelompok4_Static_Final.zip')
345   with zipfile.ZipFile(zip_path, 'w', zipfile.ZIP_DEFLATED) as z:
346       for filename in static_files:
347           z.write(ARTIFACT_DIR / filename, arcname=filename)
348
349   artifact_files_df = pd.DataFrame([
350       {'File': name, 'Ukuran (KB)': round((ARTIFACT_DIR / name).stat().st_size / 1024, 2),
351        'SHA256': hashlib.sha256((ARTIFACT_DIR / name).read_bytes()).hexdigest()[:20]}
352       for name in static_files
353   ])
354   print('\n=== BERKAS DEPLOYMENT SDK STATIC ===')
355   display(artifact_files_df)
356   print('Paket ZIP:', zip_path.resolve(), '| ukuran KB:', round(zip_path.stat().st_size/1024, 2))
357   print('sdk: static; app_file: index.html. Hosting publik harus diuji setelah upload.')
```

Gambar 22. Cuplikan kode pemeriksaan dan daftar berkas SDK Static

Sumber: UTS_DEEP_LEARNING_KELOMPOK_4_FINALE(1).ipynb, kode Section 13, baris 320-359.

9.5 Daftar Grafik dan Tabel Pendukung

Grafik utama evaluasi sudah ditampilkan pada bagian EDA dan hasil pengujian, yaitu distribusi kelas, histogram numerik, matriks korelasi, ranking tuning, perbandingan akurasi, kurva accuracy dan loss, confusion matrix, grafik confidence/permutation importance, serta ablasi. Gambar-gambar tersebut diambil dari output notebook final yang disimpan bersama file .ipynb dan tidak direkonstruksi menggunakan angka hasil perkiraan.

DAFTAR PUSTAKA

1. anshsahu111, “Laptop Specifications and Prices Dataset,” Kaggle. [Online]. Tersedia: https://www.kaggle.com/datasets/anshsahu111/laptop-specifications-and-prices-dataset (diakses 9 November 2026).
2. Google, “TensorFlow: An End-to-End Platform for Machine Learning.” [Online]. Tersedia: https://www.tensorflow.org/ (diakses 9 November 2026).
3. Keras Team, “Keras: The Deep Learning API.” [Online]. Tersedia: https://keras.io/ (diakses 9 November 2026).
4. T. O’Malley dkk., “KerasTuner,” 2019. [Online]. Tersedia: https://keras.io/keras_tuner/ (diakses 9 November 2026).
5. Scikit-learn Developers, “Common Pitfalls and Recommended Practices.” [Online]. Tersedia: https://scikit-learn.org/stable/common_pitfalls.html (diakses 9 November 2026).
6. Scikit-learn Developers, “StandardScaler.” [Online]. Tersedia: https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.StandardScaler.html (diakses 9 November 2026).
7. Scikit-learn Developers, “OneHotEncoder.” [Online]. Tersedia: https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.OneHotEncoder.html (diakses 9 November 2026).
8. Keras Team, “EarlyStopping.” [Online]. Tersedia: https://keras.io/api/callbacks/early_stopping/ (diakses 9 November 2026).
9. Keras Team, “ReduceLROnPlateau.” [Online]. Tersedia: https://keras.io/api/callbacks/reduce_lr_on_plateau/ (diakses 9 November 2026).
10. Hugging Face, “Static HTML Spaces.” [Online]. Tersedia: https://huggingface.co/docs/hub/spaces-sdks-static (diakses 9 November 2026).
11. Universitas Mikroskil, “W01 — Pengenalan Deep Learning, Tensor, dan Perceptron/MLP,” materi perkuliahan IF2110 Deep Learning, 2026.
12. Universitas Mikroskil, “W02 — Deep Learning Overview II,” materi perkuliahan IF2110 Deep Learning, 2026.
13. Universitas Mikroskil, “W03 — Deep Neural Network and Optimalization: Loss, Overfitting, L2 dan Dropout,” materi perkuliahan IF2110, 2026.
14. Universitas Mikroskil, “W04 — Batch Normalization dan Optimasi Lanjutan,” materi perkuliahan IF2110, 2026.
15. Universitas Mikroskil, “W05 — Learning Rate Scheduling, Hyperparameter Tuning, dan Early Stopping,” materi perkuliahan IF2110, 2026.

TAUTAN PROYEK UTS

Bagian terakhir mencantumkan repository GitHub dan aplikasi Hugging Face Spaces SDK Static yang digunakan dalam proyek. Tautan video demonstrasi masih menunggu publikasi; kelompok harus memasukkan URL yang bisa diakses dosen tanpa permintaan izin sebelum pengumpulan.

Tabel 22. Tautan yang wajib dilengkapi sebelum pengumpulan

Artefak	Tautan publik / status
1. Source code (GitHub)	https://github.com/x-kzy/UTS-DEEP-LEARNING
2. Video demo dan deployment	BELUM DIBERIKAN — masukkan URL YouTube atau Google Drive tanpa pembatasan akses
3. Aplikasi Hugging Face SDK Static	https://huggingface.co/spaces/Xkazuya/LAPTOP-CLASSIFIER

Sumber: Status hasil pemeriksaan file yang tersedia pada penyusunan laporan, 9 November 2026.

Sebelum pengumpulan, periksa akses publik ketiga tautan melalui jendela privat, kesesuaian metrik dengan notebook, dan kesamaan Model 3 antara pelatihan, video, serta aplikasi. Screenshot pengujian aplikasi dan tiga file batch disajikan secara terpisah di repository GitHub.